

TECH CHALLENGE — FASE 3 | BIG DATA & ANALYTICS | EMANOEL DLUGOKENSKI

Panorama do Mercado de Dados no Brasil

Uma leitura executiva das pesquisas State of Data Brasil (2021–2025), da estrutura do mercado à adoção de IA e aos desafios de retenção de talentos.



As 7 perguntas que guiam este relatório

1

Como está estruturado o mercado de dados no Brasil hoje?

2

Quais perfis profissionais são mais valorizados?

3

Como está a diversidade de gênero na área?

4

Quais tecnologias e ferramentas estão em alta?

5

Qual o nível de adoção de Inteligência Artificial?

6

Como o mercado varia por região e senioridade?

7

Quais os desafios e oportunidades para quem investe em dados?


1

Como está estruturado o mercado hoje

46%

do mercado de dados brasileiro está concentrado em São Paulo

- Analista de Dados é o cargo mais comum, seguido por Cientista e Engenheiro de Dados
- Mercado maduro: 61% dos respondentes já são Pleno, Sênior ou Especialista/Gestão
- Remuneração concentra-se entre R\$8 mil e R\$16 mil (37% dos respondentes)
- SP, MG e RJ somam quase 70% do mercado — forte concentração no eixo Sudeste




Fonte: pesquisa State of Data Brasil, consolidado via Power BI

2 Perfis mais valorizados — Formação acadêmica

47%

dos estudantes de graduação ganham até R\$3.000/mês

- Quanto maior o nível de formação, maior a concentração nas faixas salariais elevadas
- Doutorado/PhD e Pós-graduação têm presença mais relevante acima de R\$20 mil
- Mestrado apresenta a distribuição mais equilibrada entre todas as faixas
- Formação acadêmica ajuda a explicar parte da diferença salarial, mas não é o único fator



Distribuição percentual da remuneração por nível de formação


2

Perfis mais valorizados — Cargo

28%

dos Engenheiros de Dados ganham acima de R\$16 mil — o maior patamar entre os cargos

- Engenheiro de Dados e Cientista de Dados são os cargos mais bem remunerados
- Cientista de Dados: 31% concentrados em R\$8–12 mil, com cauda relevante até R\$20 mil
- Analista de BI e Analista de Dados têm remuneração mais concentrada entre R\$6–16 mil
- A diferença entre cargos técnicos avançados e cargos analíticos é clara e consistente




Distribuição percentual da remuneração por cargo

2 Perfis mais valorizados — Tempo de experiência

70%

de quem tem menos de 1 ano de experiência ganha até R\$4.000

- Tempo de experiência tem relação direta e consistente com a remuneração
- 23% dos profissionais com mais de 10 anos ganham acima de R\$16 mil
- O salto salarial mais expressivo ocorre entre 5 e 10 anos de experiência
- Experiência pesa tanto quanto — ou mais que — o cargo isoladamente



Distribuição percentual da remuneração por tempo de experiência


3

Diversidade de gênero — Evolução no tempo

22,2%

é a participação feminina no mercado em 2025 — queda frente a 2022

- Participação feminina caiu de 24,9% (2022) para 22,2% (2025)
- Homens já representam 77% do mercado em 2025, ante 74,6% em 2022
- Mulheres em cargos de gestão seguem estagnadas: 18–19% nos últimos 4 anos
- Não há, até aqui, sinal de avanço estrutural na representatividade feminina



Proporção de gênero e participação em cargos de gestão, 2022–2025


3

Diversidade de gênero — Remuneração

17,5%

é a participação feminina entre quem ganha acima de R\$40.000

- Nas faixas até R\$3.000, mulheres já são maioria ou estão próximas da paridade
- A partir de R\$16 mil, a presença feminina cai de forma acentuada
- Acima de R\$25 mil, mulheres representam apenas 17–18% dos respondentes
- O padrão sugere um 'teto de vidro' salarial: quanto mais alta a faixa, menor a presença feminina




Distribuição percentual de gênero por faixa salarial

Quais tecnologias estão em alta

54%

usam Python como principal ferramenta de ETL

- Python (54%) e SQL & Stored Procedures (53%) dominam os processos de ETL
- SQL Server (38%) e PostgreSQL (35%) lideram entre as ferramentas usadas no dia a dia
- Ambientes locais de desenvolvimento (43%) ainda superam soluções nativas em nuvem
- Orquestradores modernos como Apache Airflow (9%) têm adoção baixa — oportunidade de modernização



Ferramentas de ETL, BI e ambientes de desenvolvimento mais utilizados


5

Qual o nível de adoção de Inteligência Artificial

98%

dos profissionais já utilizam IA generativa no trabalho em 2025

- Adoção de IA generativa saltou de 74% (2023) para 98% (2025) entre os profissionais
- Empresas que tratam IA como prioridade estratégica quase dobraram: de 12% para 24%
- A parcela de empresas sem foco em IA caiu de 29% para 11% no mesmo período
- A adoção individual está à frente da priorização formal das empresas



Uso de IA generativa e prioridade estratégica das empresas, 2023–2025


6

Diferenças por região e senioridade

70%

do mercado está concentrado no eixo São Paulo, Minas Gerais e Rio de Janeiro

- São Paulo, sozinho, concentra quase metade do mercado (46%) e molda os padrões salariais nacionais
- Estados fora do eixo SP–MG–RJ somam menos de 30% dos profissionais, combinados
- 61% dos profissionais já estão em nível Pleno, Sênior ou Gestão/Especialista — mercado maduro
- Regiões menos representadas indicam oportunidade de expansão via vagas remotas



Cargos, senioridade, regiões e remuneração — visão consolidada (slide 3)

7 Desafios e oportunidades — Retenção de talento

80%

apontam remuneração como principal motivador para entrar num novo emprego

- 29% dos profissionais estão insatisfeitos no trabalho atual — patamar mais alto da série
- Remuneração também lidera os motivos de insatisfação (24%), à frente de crescimento de carreira
- Apenas 25% não buscariam novas oportunidades caso a empresa voltasse 100% presencial.
- Um retorno ao 100% presencial levaria 74% dos profissionais a buscar outra oportunidade



Busca por emprego, insatisfação e motivadores de troca, 2022–2025

Recomendações estratégicas

1

Revisar a política salarial — com foco na retenção de Engenheiros e Cientistas de Dados sênior, os perfis mais disputados do mercado.

2

Atacar a desigualdade salarial de gênero — priorizando as faixas acima de R\$20 mil, onde a queda de representatividade feminina é mais acentuada.

3


Fortalecer flexibilidade de trabalho remoto/híbrido — como alavanca de retenção — um retorno ao 100% presencial pode afastar até 74% dos profissionais.

4

Acelerar a estratégia formal de IA — para acompanhar a adoção individual, já em 98% entre os profissionais.

5

Expandir a presença fora do eixo SP–MG–RJ — para acessar talento qualificado ainda subutilizado em outras regiões.



| Diagrama e Decisões Técnicas



Visão geral do pipeline feita no draw.io



Decisão central: Camada Bronze concentrada apenas no bucket em arquivos brutos, o uso de PySpark centralizado nas etapas de tratamento (Silver e Gold).



Decisões Técnicas

- O pipeline segue o padrão Bronze → Silver → Gold: os 5 CSVs do Kaggle (2021–2025) sobem crus para o S3 (Bronze), passam por tratamento em PySpark via Glue (Silver), são filtrados e pivotados nas dimensões de negócio (Gold), e chegam ao Power BI via Athena.
- A decisão central foi simplificar a Bronze ao máximo: só arquivo puro no S3, sem Crawler e sem catalogação nessa camada.
- Como cada ano da pesquisa tem colunas (perguntas) diferentes, a solução foi despivotar os dados (melt): toda pergunta vira uma linha, no formato longo pergunta/resposta. Isso resolve a divergência de schema entre os 5 anos sem precisar unificar nomes manualmente — só que, sem cuidado, esse formato apaga a ligação entre as respostas de uma mesma pessoa. Por isso, antes do melt, cada respondente recebe um `id_resposta técnico` (chave surrogate), gerado por linha, que sobrevive à transformação.



Decisões Técnicas

- Outra decisão foi classificar as perguntas pelo código embutido (ex: P1_a, 3.f), não pelo texto — já que o texto muda de ano para ano (“Estado aonde mora?” vs “estado_onde_mora”), mas o código estrutural é mais estável. O separador foi normalizado com regex ([_.]), pois os anos usam _ ou . de forma inconsistente. Isso permite montar regras de negócio claras e reproduzíveis (codigo_1='1' AND codigo_2='a') em vez de comparar strings variáveis.
- Na Gold, a decisão foi que ela só filtra e pivota as dimensões usadas (idade, gênero, cargo, faixa salarial...), sem pré-calculer nenhuma métrica de negócio — percentuais e agregações ficam por conta do DAX no Power BI, separando responsabilidades entre pipeline (dado limpo) e ferramenta de BI (cálculo).



Obrigado

Panorama do Mercado de Dados no Brasil · State of Data Brasil (2021–2025)

Tech Challenge — Fase 3 | Big Data & Analytics

Github do projeto (Notebooks e demais materiais): https://github.com/emanoeldlugo/Tech-Challenge_Pos-Tech-Data-Analytics_Fase-3